

Guia Técnico-Científico Completo para Discussão e Submissão ao CEC (WCCI)

Otimização Multiobjetivo da Alocação de Leitos de UTI com Dados Reais do SUS

0. Objetivo do Guia

Este documento tem três objetivos claros:

- 1. Facilitar discussões técnicas aprofundadas** com orientadores e colegas, servindo como referência comum de hipóteses, decisões metodológicas e resultados.
- 2. Estruturar integralmente o trabalho** no formato esperado para submissão ao *IEEE Congress on Evolutionary Computation (CEC/WCCI)*.
- 3. Servir como base de material suplementar** (código, dados, auditoria) para garantir reproduzibilidade e impacto científico.

O foco do trabalho é a **otimização multiobjetivo da alocação de leitos de UTI**, utilizando **dados reais do SIH-SUS (Fiocruz/PCDaS)**, com implicações diretas para **gestão hospitalar e políticas públicas de saúde**.

1. Motivação Científica e Contexto

1.1. Problema Estrutural no SUS

A alocação de leitos de UTI no SUS é, na prática, baseada em regras simples (FIFO, priorizações administrativas ou decisões ad hoc), que **não consideram explicitamente trade-offs entre risco clínico, tempo de espera e utilização da capacidade**.

Dados reais do SIH-SUS revelam: - Alta variabilidade no tempo de permanência em UTI - Presença recorrente de pacientes de longa permanência - Gargalos estruturais em especialidades críticas (neonatologia, cardiologia, neurologia)

1.2. Lacuna na Literatura

A literatura em *healthcare optimization* apresenta: - Modelos estocásticos e de simulação - Problemas de scheduling hospitalar com dados sintéticos - Otimização mono-objetivo ou com poucos objetivos

👉 **Lacuna identificada:** ausência de frameworks **multiobjetivo, escaláveis e validados com dados reais do SUS**, conectando diretamente resultados algorítmicos a decisões de capacidade.

2. Dados Reais e Análise Exploratória (EDA)

2.1. Fonte dos Dados

- Sistema: **SIH-SUS**
- Acesso: **PCDaS / Fiocruz**
- Município: **Juiz de Fora - MG (código 313670)**
- Período agregado: múltiplos meses (≈ 125.000 registros brutos)

2.2. Processamento Inicial

Scripts principais: - `gerar_bases_reais.py` - `analise_bases.py`

Etapas: 1. Filtragem por município 2. Remoção de duplicidades administrativas 3. Consolidação multi-mês 4. Validação de consistência temporal

2.3. Engenharia de Features Clínicas

Variável	Origem	Transformação
<code>id_paciente</code>	N_AIH	Identificador único
<code>tempo_chegada_hora</code>	DT_INTER	Offset em horas desde início do período
<code>tempo_estimado_uti_horas</code>	DIAS_PERM	Dias \times 24 (Oráculo)
<code>gravidade_score</code>	Derivada	Combinação de complexidade, idade e tipo de UTI

Fórmula do Score de Gravidade

- Alta complexidade (COMPLEX = 03): +4
- Internação de urgência (CAR_INT = 02): +3
- Idade > 70 anos: +2
- UTI Tipo III (MARCA_UTI = 76 ou 82): +1

Score final $\in [1, 10]$

2.4. Análise Exploratória Recomendada (para o artigo)

Resultados observados: - Distribuição altamente assimétrica de permanência (cauda longa) - Pequeno subconjunto de pacientes responde por grande parte da ocupação total - Correlação positiva entre gravidade e tempo de permanência

👉 Esses padrões **motivam diretamente** a formulação multiobjetivo e explicam o surgimento do *débito estrutural*.

3. Formulação do Problema de Otimização

3.1. Variáveis de Decisão

Para cada paciente i :

$$x_i = \text{tempo de início da internação em UTI}$$

Domínio:

$$x_i \in [t_i^{chegada}, T_{horizonte}]$$

3.2. Funções Objetivo (Minimização)

1. Tempo Total de Espera (normalizado)

$$f_1 = \frac{\sum(x_i - t_i^{chegada})}{\text{ref}_{espera}}$$

2. Ociosidade de Leitos

$$f_2 = 1 - \text{taxa de utilização}$$

3. Risco Clínico Agregado (normalizado)

$$f_3 = \frac{\sum(\text{gravidade}_i \times \text{espera}_i)}{\text{ref}_{risco}}$$

4. Custo Terminal (normalizado)

$$f_4 = \frac{\text{ocupação após horizonte}}{\text{ref}_{terminal}}$$

3.3. Restrições Rígidas

1. **Capacidade Física:** ocupação simultânea \leq número de leitos

2. **Precedência Temporal:** $x_i \geq$ tempo de chegada

4. Metodologia Algorítmica

4.1. NSGA-II

- Non-dominated Sorting
- Crowding Distance
- Operadores:
 - SBX (crossover)
 - Polynomial Mutation

Parâmetros típicos: - População: 350 - Gerações: 250

4.2. GDE3

- Differential Evolution multiobjetivo
- Variantes testadas:
 - DE/rand/1/bin (exploratória)
 - DE/best/1/bin (explotativa)
 - DE/rand-to-best/1/bin (balanceada)

4.3. Justificativa dos Parâmetros

- População elevada garante cobertura do espaço 4D
 - Número de gerações definido por estabilização empírica da fronteira
 - Mesmos dados e restrições para comparação justa
-

5. Setup Experimental

5.1. Cenários Simulados com Dados Reais

Cenário	Pacientes	Leitos	Ocupação
Underload	31	12	45%
Central	62	12	90%
Overload	78	12	130%
Massivo	1.171	186–278	Escala real

5.2. Horizonte de Planejamento

- 1.200 horas (50 dias)
-

6. Resultados Principais

6.1. Comparação Algorítmica

Resultados mostram que:
- NSGA-II domina o GDE3 em todos os cenários
- Melhor trade-off risco × espera
- Maior estabilidade da fronteira de Pareto

6.2. Descoberta do Débito Estrutural

- Débito \approx 6.900 horas observado em múltiplos cenários
- Invariante ao número de leitos
- Associado a pacientes crônicos de longa permanência

👉 Interpretação: limite **clínico**, não gerencial.

6.3. Ponto de Inflexão da Capacidade

- 186 leitos \rightarrow crise gerenciada

- 233 leitos → eficiência ótima
- 265+ leitos → folga operacional

Delta crítico ≈ 79 leitos

7. Auditoria Clínica e Validação

- Rastreabilidade paciente a paciente
 - Casos reais auditados nas bases originais
 - Perfil epidemiológico consistente com literatura médica
-

8. Implicações para Políticas Públicas

- Quantificação objetiva da necessidade de expansão
 - Evidência empírica para planejamento hospitalar
 - Ferramenta de alerta precoce para overload
-

9. Contribuições Científicas

9.1. Metodológicas

- Framework multiobjetivo escalável com dados reais
- Integração entre otimização e auditoria clínica

9.2. Empíricas

- Uso extensivo de dados do SUS
- Curvas reais de sensibilidade capacidade × espera

9.3. Aplicadas

- Suporte direto à decisão pública
-

10. Próximos Passos

1. Refinar EDA para submissão
 2. Consolidar gráficos de convergência
 3. Preparar versão estendida para periódico
-

11. Conclusão

O trabalho demonstra que **otimização multiobjetivo com dados reais do SUS é viável, escalável e cientificamente relevante**, revelando limites estruturais invisíveis a abordagens tradicionais e fornecendo evidências açãoáveis para a gestão pública de saúde.